

# 목차

---

1. [서론](#)
2. [모델 설명](#)
  - [기존 연구](#)
  - [과제 모델](#)
3. [실험 설계](#)
4. [실험 결과 및 분석](#)
5. [결론](#)
6. [레퍼런스](#)

## 서론

---

Sentence classification model을 구현하고 성능을 평가하여 기존 연구와 정량적 성능을 비교해 보기로 한다. 모델의 설계와 구현은 아래의 Yoon Kim의 논문과 그 구현 코드들을 참고하였다.

- Yoon Kim - Convolutional Neural Networks for Sentence Classification <sup>1</sup>
- Implementing a CNN for Text Classification in Tensorflow <sup>2</sup>
- yoonkim - CNN\_sentence <sup>3</sup>
- dennybritz - cnn-text\_classification-tf <sup>4</sup>

기존 연구는 문장의 단어들을 table lookup을 이용해 임베딩한 후 CNN 모델의 input으로 사용하였으나 본 과제에서는 CNN으로 Character-level word embedding을 수행한다. 그리고 기존 연구 모델에 더해서 RNN 기반 모델을 설계하여 기존 연구와 두 개의 모델간의 성능을 비교한다.


## 모델 설명

---

### 기존 연구

---

#### Yoon Kim (2014)의 아키텍처




첫 번째 레이어는 단어를 저차원 벡터로 임베딩한다. 다음 레이어는 여러 사이즈의 필터로, 임베딩 된 단어 벡터에 대해 concatenation 을 수행한다. 다음에는 그것을 맥스 풀링하고, 드롭아웃을 적용하고, 소프트맥스 레이어의 결과로 분류를 수행한다.

## 과제 모델

### Word Embedding

논문에는 Word2Vec 벡터를 사용했으나 본 과제에서는 Character-level embedding을 수행하여 얻은 벡터를 사용한다. Character-level embedding에는 CNN을 이용한다. 전반적인 성능 향상, 특히 Out-Of-Vocabulary 단어에 대하여 큰 성능 향상을 기대할 수 있다.

#### Character-level Feature - CNN




단어의 모든 문자들을 CNN 레이어의 input으로 넣고 output을 맥스풀링한 결과를 취한다.

## Core Layer

### CNN for Sentence Classification

위에서 설명한 기존 연구의 모델과 동일하다.

### RNN for Sentence Classification



Character-level embedding 결과 벡터를 Bi-directional LSTM의 input으로 활용하여 그 output으로 분류를 수행한다. LSTM의 output은 3차원 텐서([pos, neg, neut])이며, 가장 값이 큰 요소를 결과로서 출력한다.

## Hyper Parameters

## 실험 설계

## 평가 지표

# Confusion Matrix

		Predicted	
		Positive	Negative
Actual	Positive	TP (True Positive)	FN (False Negative)
	Negative	FP (False Positive)	TN (True Negative)

## 1. Accuracy

- 모델이 샘플을 정확히 분류한 비율.
- 

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN}$$

## 2. Precision

- 모델이 positive로 분류한 샘플 중 실제로 positive인 비율.
- 

$$Precision = \frac{TP}{TP + FP}$$

## 3. Recall

- positive 샘플 중 모델이 positive로 분류한 비율.
- 

$$Recall = \frac{TP}{TP + FN}$$

## 4. Fallout

- negative 샘플 중 모델이 positive로 잘못 분류한 비율.
- 

$$Fallout = \frac{FP}{TN + FP}$$


## 5. F1 score

- Precision과 Recall의 조화 평균.
-

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} = \frac{2TP}{2TP + FP + FN}$$

## 6. ROC (Receiver Operating Characteristic) Curve

- Fallout과 Recall의 변화를 시각화한 것.
- Recall이 크고, Fallout이 작은 모형을 좋은 모형으로 생각할 수 있다.
- 곡선이 왼쪽 위 모서리에 가까울 수록 모델 성능이 좋다.



## 7. AUC (Area Under the Curve)

- ROC Curve의 밑면적을 계산한 값.
- Fallout 대비 Recall값이 클 수록 AUC가 1에 가까운 값이며 우수한 모형이다.

# 실험 결과 및 분석

## 결론

## 레퍼런스

- Yoon Kim - Convolutional Neural Networks for Sentence Classification <sup>1</sup>
- Implementing a CNN for Text Classification in Tensorflow <sup>2</sup>
- yoonkim - CNN\_sentence <sup>3</sup>
- dennybritz - cnn-text\_classification-tf <sup>4</sup>

- 분류모델 성능 평가 지표 5

- 
1. <http://www.aclweb.org/anthology/D14-1181>
  2. <http://www.wildml.com/2015/12/implementing-a-cnn-for-text-classification-in-tensorflow/>
  3. [https://github.com/voonkim/CNN\\_sentence](https://github.com/voonkim/CNN_sentence)
  4. <https://github.com/dennybritz/cnn-text-classification-tf>
  5. <http://here.deeppplus.co.kr/?p=24>